

How to Split a Node

How to Split a Node: Single Variable

- Asumsikan kita punya variabel **income** dan ingin memprediksi **debt**

Feature Space dari variabel **income**


Min : 2.5 juta



Max : 15 juta

How to Split a Node: **Single Variable**

- Asumsikan kita punya variabel **income** dan ingin memprediksi **debt**
 - Hitung **mean square error** di setiap angka pada feature space
- kita membaginya semisal menjadi 3 bagian.
 S1 untuk income > 4jt
 S2 untuk income > 8jt
 S3 untuk income > 12 juta



Mana yang dipilih?

How to Split a Node: Single Variable

- Asumsikan kita punya variabel **income** dan ingin memprediksi **debt**
- Hitung **mean square error** di setiap angka pada feature space

1. Model Membagi Data Menjadi 2 Grup

Berdasarkan pertanyaan di atas, 5 orang tadi terbagi menjadi:


Grup	Income	Debt (Aktual)
Grup Kiri (<code>Income</code> $\leq$ 8jt)	4 juta	5 juta
	6 juta	4 juta
	7 juta	6 juta
Grup Kanan (<code>Income</code> $>$ 8jt)	10 juta	10 juta
	12 juta	9 juta

2. Model Membuat Prediksi untuk Tiap Grup

Model akan memprediksi nilai `debt` untuk tiap grup dengan cara mengambil nilai **rata-rata** dari grup tersebut.

- **Prediksi untuk Grup Kiri:** $(5 + 4 + 6) / 3 = 15 / 3 = 5 \text{ juta}$ (Jadi, untuk semua orang di Grup Kiri, prediksinya adalah 5 juta)
- **Prediksi untuk Grup Kanan:** $(10 + 9) / 2 = 19 / 2 = 9.5 \text{ juta}$ (Jadi, untuk semua orang di Grup Kanan, prediksinya adalah 9.5 juta)

$$\text{MSE} = 0.6$$



3. Model Menghitung Error Kuadrat (MSE)

Sekarang kita hitung selisih kuadrat antara nilai **Aktual** dan **Prediksi** untuk setiap orang.

Grup	Debt (Aktual)	Prediksi Grup	Selisih (Error)	Error Kuadrat
Kiri	5 juta	5 juta	0	$0^2 = 0$
Kiri	4 juta	5 juta	-1	$(-1)^2 = 1$
Kiri	6 juta	5 juta	1	$1^2 = 1$
Kanan	10 juta	9.5 juta	0.5	$(0.5)^2 = 0.25$
Kanan	9 juta	9.5 juta	-0.5	$(-0.5)^2 = 0.25$
Total Error Kuadrat				3

Ekspor ke Spreadsheet

Akhirnya, kita ambil **rata-rata** dari semua Error Kuadrat:

$$\text{MSE} = (\text{Total Error Kuadrat}) / (\text{Jumlah Data}) \quad \text{MSE} = (0 + 1 + 1 + 0.25 + 0.25) / 5 \quad \text{MSE} = 3 / 5 \quad \text{MSE} = 0.6$$

Pertanyaan

- Ada berapa banyak cara untuk melakukan *splitting*?
- Bagaimana kalau kita memiliki **banyak variabel** (atribut/fitur)?


Choosing variable to split

Variable 1	Split in S_1	MSE = 3,143
Variable 2	Split in S_2	MSE = 1,433
Variable 3	Split in S_3	MSE = 4,331
$\vdots$	$\vdots$	$\vdots$
Variable k	Split in S_k	MSE = 3,314

Yang mana yang kita pilih?

Greedy Algorithm

- Tree dibentuk secara rekursif, **satu branch** tiap waktu.



- Split ditentukan pada kondisi yang paling besar menurunkan *cost function*, J
- Algoritma dihentikan ketika *stopping criterion* tercapai.

Regression & Classification

Regression	Classification
Output: • $f(\mathbf{x}): \mathbb{R}^p \rightarrow \mathbb{R}$	Output: • Binary Classification: $\Omega = \{-1, 1\}$ • Multi-class Classification: $\Omega = \{1, 2, 3, \dots, C\}$ • $f(\mathbf{x}): \mathbb{R}^p \rightarrow \Omega$