

Choosing the Best Attribute


Choosing the best attribute

- **Key problem:** memilih atribut mana yang dipakai untuk memisahkan data.
- Beberapa opsi:
 - **Random** → Pilih atribut secara acak (random)
 - **Least Values** → Pilih atribut dengan jumlah *possible value* terkecil cuman ada pilihan Yes atau No
 - **Most Values** → Pilih atribut dengan jumlah *possible value* terbesar misal pembagian berdasarkan gaji di file sebelumnya, min = 2jt, max = 11jt
 - **Max-Gain** → pilih atribut yang memiliki **information gain** terbesar.
 - yang mana akan memperkecil ukuran tree.

Information Gain


- Uji mana yang lebih informatif?

Membagi apa **Price** lebih dari 50k atau tidak



ternyata pembagian Hungry dan Not Hungry kurang informatif ke Machine Learning Decision Tree, kenapa? ya karena informasi nya kurang gitu, semisal kaya data dibawah,

Membagi apa applicant lapar/tidak




Impurity/Entropy Calculation

- **Entropy** : mengukur tingkat **impurity** dari grup


Very impure group

nah kalo ini kan masih banyak selain hijau, tapi ada juga yang +, sehingga disarankan mesin untuk belajar lagi, demi mencapai pembagian data yang lebih murni lagi




Less impure

kalo ini ada ketambahan dikit tapi biasanya ga di wajibin untuk belajar lagi, karena udah dominan oleh warna hijau



Minimum impurity

dimulai dari sini, sebenarnya ini dan ngindikasin sih, kalo data udah murni tinggal 1 macem doang atau tinggal 1 jenis variasi data doang. sehingga machine learning decision tree ga perlu belajar lagi




based on slide by Pedro Domingos

Impurity/Entropy Calculation

- Entropy, $H(x)$

$$H(x) = - \sum_{i=1}^n P(x = i) \log_2 P(x = i)$$

$P(x=i)$ adalah probability dari kelas- i . Dihitung sebagai proporsi kelas- i pada set.



Impurity/Entropy Calculation


- Berapa entropi dari grup ketika semua anggotanya homogen (ada pada kelas yang sama)?

$$i = 1, P(x = i) = 1.0$$

$$\text{Entropi} = -1 \times \log_2(1) = 0$$

→ MINIMUM IMPURITY

Bukan set yang bagus untuk belajar, melainkan untuk final saja



- Berapa entropi dari grup ketika anggotanya 50% dari kelas 1 dan sisanya kelas 2?


$$i = 1, P(x = i) = 0.5$$

$$i = 2, P(x = i) = 0.5$$

$$\text{Entropi} = -(0.5 \times \log_2(0.5) + 0.5 \times \log_2(0.5)) = 1$$

→ MAXIMUM IMPURITY

Set yang bagus untuk decision tree belajar, maksudnya masih bisa digunakan untuk menghasilkan keputusan lagi.



Measure of Impurity

- Selain entropy, ada juga gini index & classification error untuk menghitung error

