

Decision Tree: Another Construction

Model a patron's decision of whether to wait for a table at a restaurant


Example	Attributes										Target <i>Wait</i>
	<i>Alt</i>	<i>Bar</i>	<i>Fri</i>	<i>Hun</i>	<i>Pat</i>	<i>Price</i>	<i>Rain</i>	<i>Res</i>	<i>Type</i>	<i>Est</i>	
X_1	T	F	F	T	Some	\$\$\$	F	T	French	0-10	T
X_2	T	F	F	T	Full	\$	F	F	Thai	30-60	F
X_3	F	T	F	F	Some	\$	F	F	Burger	0-10	T
X_4	T	F	T	T	Full	\$	F	F	Thai	10-30	T
X_5	T	F	T	F	Full	\$\$\$	F	T	French	>60	F
X_6	F	T	F	T	Some	\$\$	T	T	Italian	0-10	T
X_7	F	T	F	F	None	\$	T	F	Burger	0-10	F
X_8	F	F	F	T	Some	\$\$	T	T	Thai	0-10	T
X_9	F	T	T	F	Full	\$	T	F	Burger	>60	F
X_{10}	T	T	T	T	Full	\$\$\$	F	T	Italian	10-30	F
X_{11}	F	F	F	F	None	\$	F	F	Thai	0-10	F
X_{12}	T	T	T	T	Full	\$	F	F	Burger	30-60	T

~7,000 possible cases

based on slide by Eric Eaton

Choosing an attribute

- **Ide**, atribut yang baik membagi data menjadi subset yang ideal, “semua positif” atau “semua negatif”



Based on slide by Pedro Domingos


- Pembagian mana yang lebih **informatif?** Patrons atau Type?

Choosing **next** attribute

- **Ide**, cari atribut selanjutnya yang paling menurunkan entropi diketahui atribut sebelumnya.
- Ini disebut dengan **information gain**

information gain = **entropy**(parent) – [**average entropy** (children)]

Choosing next attribute



1. Dari mana $H(S) = 0.94$? (Kekacauan Awal)

Ini adalah grup awal (node "Windy") sebelum dibagi.

- Total Data: 14
- Jumlah "yes": 9
- Jumlah "no": 5

Maka:

- $p(yes) = 9/14 \approx 0.643$
- $p(no) = 5/14 \approx 0.357$

Hitungan: Entropy = $-(0.643 * \log_2(0.643)) - (0.357 * \log_2(0.357))$ Entropy = $-(0.643 * -0.637) - (0.357 * -1.485)$ Entropy = $-(-0.409) - (-0.530)$ Entropy = $0.409 + 0.530 = 0.939$...dibulatkan menjadi **0.94**.

2. Dari mana $H(S_{False}) = 0.81$? (Kekacauan Cabang "False")

Ini adalah grup setelah menjawab "False".

- Total Data: 8
- Jumlah "yes": 6
- Jumlah "no": 2

Maka:

- $p(yes) = 6/8 = 0.75$
- $p(no) = 2/8 = 0.25$

Hitungan: Entropy = $-(0.75 * \log_2(0.75)) - (0.25 * \log_2(0.25))$ Entropy = $-(0.75 * -0.415) - (0.25 * -2.0)$ Entropy = $-(-0.311) - (-0.5)$ Entropy = $0.311 + 0.5 = 0.811$...dibulatkan menjadi **0.81**.

$$H(S) = 0.94, H(S_{False}) = 0.81, H(S_{True}) = 1.0$$
$$Gain(S, Windy) = 0.94 - \frac{8}{14}0.81 - \frac{6}{14}1.0 = 0.049$$

3. Dari mana $H(S_{True}) = 1.0$? (Kekacauan Cabang "True")

Ini adalah grup setelah menjawab "True".

- Total Data: 6
- Jumlah "yes": 3
- Jumlah "no": 3


Maka:

- $p(yes) = 3/6 = 0.5$
- $p(no) = 3/6 = 0.5$

Hitungan: Entropy = $-(0.5 * \log_2(0.5)) - (0.5 * \log_2(0.5))$ Entropy = $-(0.5 * -1.0) - (0.5 * -1.0)$ Entropy = $-(-0.5) - (-0.5)$ Entropy = $0.5 + 0.5 = 1.0$


hasil 0.049 sebenarnya kecil. ya karena hanya 0.0 ... 49
sehingga kalo ada atribut lain yang bisa digunakan dan diharapkan nilai gain informationnya lebih gede

After choosing the best attribute



based on slide by M. desJardins & T. Finin

Compare the two decision tree



based on slide by M. desJardins & T. Finin