

Limitation of Trees

Why trees are widely used in practice

- Dapat memodelkan **high dimensional data** ga kaya KNN yang makin gede dimensi makin ga jelas
- Trees dapat diinterpretasikan bisa lihat batasan data berdasarkan kotak kotak yang udah di buat sama decision tree, sehingga mudah dibaca
 - Domain expert dapat **membaca** logika tree sebagai “rules”
- Algoritma tree mudah untuk di **code** dan diuji bisa nulis batasan untuk aturan data semisal yang gajinya > 5j atau > 8jt


Limitation of trees

- Kesulitan dalam memodelkan struktur linear
- Kurang *smooth*


tapi kalo model datanya linear, kurang cocok ya karena nanti mempetakan datanya nanti jadi ga ada yg ke potong jelas

Linear boundary

Linear model





Tree-based model



sebaliknya kalo tipe datanya kotak kata exercise kemarin, ga cocok di linear

Non-linear boundary



Limitation of trees

- Variasi model yang tinggi
 - Trees tergolong “tidak stabil” sebagai fungsi dari sampel
 - Akibatnya:
 - Variasi besar (high variance) pada prediksi error.
 - Variasi besar yang menurunkan interpretabilitas.

jadi datanya berubah dikit aja, nanti ke mesin bisa beda bentuk juga modelnya

- Trees dapat dijadikan kandidat bagus untuk gabungan model
 - sering digunakan dengan boosting & bagging.

Bagging (Random Forest): ambil banyak pohon, latih dengan data acak, lalu rata-rata hasilnya → stabil.

Boosting (XGBoost, AdaBoost): gabungkan banyak pohon kecil untuk memperbaiki kesalahan pohon sebelumnya.

Contoh Kasus

Kamu punya data kecil seperti ini:

ID	Umur	Gaji	Beli Produk?
1	25	5 jt	Tidak
2	30	7 jt	Ya
3	35	8 jt	Ya
4	40	6 jt	Tidak

Sekarang kamu latih **Decision Tree**.

Kalau kamu **acak urutan data** atau **hapus satu baris data**, hasil pohonnya bisa **berubah total**.

Contohnya:

1. Model 1 (data versi A)

- “Kalau umur > 32 → Ya, kalau tidak → Tidak.”
→ pohonnya berdasarkan umur.

2. Model 2 (data versi B)

- “Kalau gaji > 6.5 jt → Ya, kalau tidak → Tidak.”
→ pohonnya berdasarkan gaji.

Padahal datanya mirip banget!

Tapi pohon yang terbentuk bisa **berbeda struktur** dan **hasilnya pun beda**.

Decision trees are not stable

- Merubah satu data “sedikit” dapat mengakibatkan perbedaan yang cukup signifikan terhadap partisi.

lihat yang di bulat hijau
kita meletakan perbedaan
lokasi titiknya
hasil region dari
decision tree juga akan berubah

dah gitu hasil logic nya (yg kanan)
juga berubah,






Figure from Duda, Hart & Stork, Chap. 8
Data mining- Volinsky - 2011 - Columbia University

Thank You
