

Resampling Method

Introduction to Machine Learning

Referensi

- An Introduction to Statistical Learning
— *Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani*
- The Elements of Statistical Learning
— *Trevor Hastie, Robert Tibshirani, Jerome Friedman*

Outcomes

- Siswa dapat **menyebutkan** metrik untuk menentukan performa klasifikasi & regresi
- Siswa dapat **menjelaskan** metode resampling

Outline

- Bias – Variance
- Regression and Classification Metric Performance
- Good Test Error
- Resampling Method
 - Validation approach
 - Cross-validation
 - Bootstrap

Bias - Variance

A good model

Bagaimana cara menentukan **kualitas model yang baik** dalam sudut pandang machine learning?

Regression & Classification

Diberikan suatu input X

Regression	Classification
Output: • $f(\mathbf{x}): \mathbb{R}^p \rightarrow \mathbb{R}$	Output: • Binary Classification: $\Omega = \{-1, 1\}$ • Multi-class Classification: $\Omega = \{1, 2, 3, \dots, C\}$ • $f(\mathbf{x}): \mathbb{R}^p \rightarrow \Omega$

Evaluation Metrics

Regression

Mana hasil prediksi yang lebih baik?

Misal:

Diberikan suatu budget Ads, berapa new user yang didapat?

	Nilai asli	Model A	Model B
# New User	30	29	10

Regression

Mana hasil prediksi yang lebih baik?

Misal:

Diberikan suatu budget Ads, berapa new user yang didapat?

	Nilai asli	Model A	Model B
# New User	30	29	10

Model A

Karena hasil prediksi model A **lebih dekat** dengan nilai aslinya

Regression

- MSE (Mean Square Error)

$$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- RMSE (Root Mean Square Error)

$$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- MAE (Mean Absolute Error)

$$\frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

y_i : nilai target asli

$\hat{y}_i$: nilai prediksi

Regression: MSE

- Artinya apa sih?

$$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Selisih hasil prediksi dengan nilai asli

Sejauh apa **deviasi** nilai prediksi dengan nilai asli — jarak

Regression: MSE

- Artinya apa sih?

$$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Dikuadratkan karena jarak
(jauh/dekat) harus positif

Bisa juga dengan mutlak → MAE

Regression: MSE

- Artinya apa sih?

$$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Untuk mendapatkan jumlah
error/deviasi seluruh data

Regression: MSE

- Artinya apa sih?

$$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Dirata-ratakan agar dapat ukuran error normal sehingga dapat dibandingkan.

Classification

Mana hasil prediksi yang lebih baik?

Misal:

Melakukan klasifikasi binary (target kelas ada 2, misal +1 dan -1). Berikut output yang mungkin.

Nilai Asli	Nilai Prediksi
+1	+1
-1	-1

Classification

Mana hasil prediksi yang lebih baik?

Misal:

Melakukan klasifikasi binary (target kelas ada 2, misal +1 dan -1). Berikut output yang mungkin.

Nilai Asli	Nilai Prediksi
+1	+1
-1	-1
+1	-1
-1	+1

Classification

Mana hasil prediksi yang lebih baik?

Misal:

Melakukan klasifikasi binary (target kelas ada 2, misal +1 dan -1). Berikut output yang mungkin.

Nilai Asli	Nilai Prediksi	
+1	+1	Good prediction
-1	-1	Good prediction
+1	-1	Bad prediction
-1	+1	Bad prediction

Classification

Bisa dirangkum dengan **confusion matrix**

		Prediction	
		+1	-1
Actual	+1	TP	FN
	-1	FP	TN

True Positive : TP
 True Negative : TN
 False Positive : FP
 False Negative : FN

Classification

Akurasi = #prediksi benar / #data

		Prediction	
		+1	-1
Actual	+1	TP = 40	FN = 10
	-1	FP = 3	TN = 47

$$\begin{aligned}
 \text{Accuracy} &= \frac{TP + TN}{TP + TN + FP + FN} \\
 &= \frac{40 + 47}{40 + 47 + 3 + 10} \\
 &= 0.87
 \end{aligned}$$

Classification

Akurasi = #prediksi benar / #data

		Prediction	
		+1	-1
Actual	+1	TP = 1	FN = 9
	-1	FP = 3	TN = 987

$$\begin{aligned}
 \text{Accuracy} &= \frac{TP + TN}{TP + TN + FP + FN} \\
 &= \frac{1 + 987}{1 + 987 + 3 + 9} \\
 &= 0.98
 \end{aligned}$$

Classification

Akurasi = #prediksi benar / #data

		Prediction	
		+1	-1
Actual	+1	TP = 1	FN = 9
	-1	FP = 3	TN = 987

$$\begin{aligned}
 \text{Accuracy} &= \frac{TP + TN}{TP + TN + FP + FN} \\
 &= \frac{1 + 987}{1 + 987 + 3 + 9} \\
 &= 0.98
 \end{aligned}$$

Akurasi tinggi, namun model gagal memprediksi kelas +1

Akurasi prediksi kelas +1 hanya 10%

Classification

Akurasi = $\frac{\text{\#prediksi benar}}{\text{\#data}}$

		Prediction	
		+1	-1
Actual	+1	TP	FN
	-1	FP	TN

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

Classification

Akurasi = #prediksi benar / #data

		Prediction	
		+1	-1
Actual	+1	TP = 1	FN = 9
	-1	FP = 3	TN = 987

$$\begin{aligned}
 \text{Recall} &= \frac{TP}{TP + FN} \\
 &= \frac{1}{1 + 9} \\
 &= 0.1
 \end{aligned}$$


Good Approximations

Method of evaluation

- Metode dasar untuk evaluasi adalah **validasi model** pada dataset yang **berbeda** dan **independen** dari sumber yang sama, yakni **testing data**.


Method of evaluation

...on Training data. ①




✖ 30 ✖ 10 error: 22.5%
 ● 32 ● 8 acc.: 77.5%

...on Training data. ②




✖ 37 ✖ 3 error: 7.5%
 ● 37 ● 3 acc.: 92.5%

...on Training data. ③




✖ 37 ✖ 0 error: 0%
 ● 37 ● 0 acc.: 100%

...on Test data. ④




✖ 32 ✖ 8 error: 23.8%
 ● 29 ● 11 acc.: 76.2%

...on Test data. ⑤



✖ 37 ✖ 3 error: 11.3%
 ● 34 ● 6 acc.: 88.7%

...on Test data. ⑥




✖ 34 ✖ 6 error: 21.3%
 ● 29 ● 11 acc.: 78.7%



How to have a good test error?

Model Complexity

- Jika model terlalu sederhana, solusi akan **bias** dan tidak **fit** pada data.
- Jika model **terlalu kompleks**, model akan sensitif terhadap perubahan pada data.



Underfitting & Overfitting




Model berubah jauh (sensitive) ketika **data training berbeda**.

Ini disebut **high variance**

Underfitting & Overfitting

	Bias	Variance	Complexity	Generalizability
Underfitting Model yang terlalu sederhana	High	Low	Low	High
Overfitting Model Anda belajar noise pada data	Low	High	High	Low

Underfitting & Overfitting




Model Complexity

- Tujuan kita untuk **mendekati** best fitted model
- **Problem:** butuh tambahan informasi untuk menguji apakah model near-best fitted, underfitting, atau overfitting.
- **Solusi:** butuh resampling methods untuk mendapatkan tambahan informasi.

Resampling Methods


What is Resampling?

- Mengambil sampel dari data training.



What is Resampling?


- Fit model ke setiap set resample
- Kemudian cek performa model di setiap set tersebut.



Validation Set Approach


Validation Set Approach

- Bagi secara random dan berimbang dataset
 - Training set → untuk fitting model
 - Validation set → untuk validasi performa





Validation Set Approach

- Bagi secara random dan berimbang dataset
 - Training set → untuk fitting model
 - Validation set → untuk validasi performa



Validation Set Approach


- Kekurangan:
 - Apabila proses dilakukan beberapa kali, MSE validasi yang didapat beda disetiap perulangan → bergantung set yang didapat.
 - MSE validasi cenderung overestimate → gunakan separuh data training untuk fitting model.



Cross Validation

K-Fold Cross Validation


- Idenya, bagi data secara random ke dalam k-bagian



K-Fold Cross Validation

1. Pilih fold-1, jadikan validation set. Fold lain dijadikan training set
2. Fit model pada training set, kemudian hitung performanya.
3. Lakukan step #1 & #2 untuk seluruh fold lain, sehingga dapat model.
4. Hitung CV score final dengan

$$CV_k = \frac{1}{k} \sum_{i=1}^k \text{error}_i$$





K-Fold Cross Validation

- CV score adalah **performa model** anda.
- Pilih **model terbaik** berdasarkan CV score terbaik.
- Selanjutnya **buat model final** dengan kombinasi parameter **model terbaik** menggunakan **seluruh data training**.

Bootstrap

Bootstrap: Intuition

- Menyimulasikan ketidakpastian (uncertainties) dari data




Garis merah
true function

Garis biru
model dari
observed/sampled data

Garis biru muda
model dari sampel data
lain

Bootstrap: Intuition

- Data sampel diambil dari populasi, dan berharap dapat mengestimasi populasi.




Bootstrap: Intuition

- Apa data sekarang sudah **cukup bagus** untuk merepresentasikan populasi?

Bootstrap: Intuition

- Apa data sekarang sudah **cukup bagus** untuk merepresentasikan populasi?
Belum tentu, karena data training kita hanyalah 1 set sampel dari populasi



Bootstrap: Intuition

- Bagaimana kalau kita bisa mendapatkan **sampel set yang baru?**

Bootstrap: Intuition


- Bagaimana kalau kita bisa mendapatkan **sampel set yang baru?**
Mungkin, tapi kecil karena kita harus melakukan pengambilan sampel lagi

Bootstrap: Intuition

- Bagaimana kalau kita bisa membuat sampel set baru dari **sampel set sekarang?**


Bootstrap: Intuition

- Bagaimana kalau kita bisa membuat sampel set baru dari **sampel set sekarang?**
Ya, kita bisa membuat sampel set baru dengan resampling sampel set yang kita miliki sekarang.






Bootstrap example

- Melakukan resampling secara **acak dengan pengembalian** dengan **ukuran yang sama** seperti sampel asli.
- Bootstrap pada gambar ini digunakan untuk mengestimasi nilai alpha (α)



Bootstrap Results

- Bootstrap menghasilkan B nilai alpha (α), sehingga dapat ditentukan standar errornya.
- Bootstrap dapat mengestimasi variability dari nilai yang ingin dicari (alpha)



Thank You
